R2AI GURU · STAGE 3 · DEMO DAY

TRUY HỒI TÀI LIỆU Y KHOA ĐA NGÔN NGỮ VIỆT – TRUNG

Một hệ thống truy hồi chạy trọn trên một máy cá nhân: RTX 3050 6 GB, 16 GB RAM, không cloud GPU.

PUBLIC FINAL 0,2483 | 4,39M URL | 7,6M CHUNK | 1 GPU · 6 GB

LÊ NGỌC TÚ

19/10/2026

01 · BÀI TOÁN

TÌM ĐÚNG TÀI LIỆU VÀ ĐÚNG ĐOẠN VĂN

4,39 triệu URL

97 domain y tế, tiếng Việt và tiếng Trung. Đội thi tự crawl, làm sạch, chia chunk và lập chỉ mục.

1.200 câu hỏi

Câu hỏi y khoa tiếng Việt. Bảng Public chấm 600 câu; Private dùng bộ câu khác.

2 tầng F2

FINAL = trung bình (Docs F2, Chunks F2). Recall nặng gấp 4 lần Precision. Chunk đúng khi LCS ≥ 0,40.

MODEL OPEN-WEIGHT ≤ 15B

PHÁT HÀNH TRƯỚC 01/08/2026

ZIP ≤ 100 MB

CHUNK ≤ 1.024 TOKEN

02 · RÀNG BUỘC PHẦN CỨNG

MỘT MÁY CÁ NHÂN, KHÔNG CLOUD

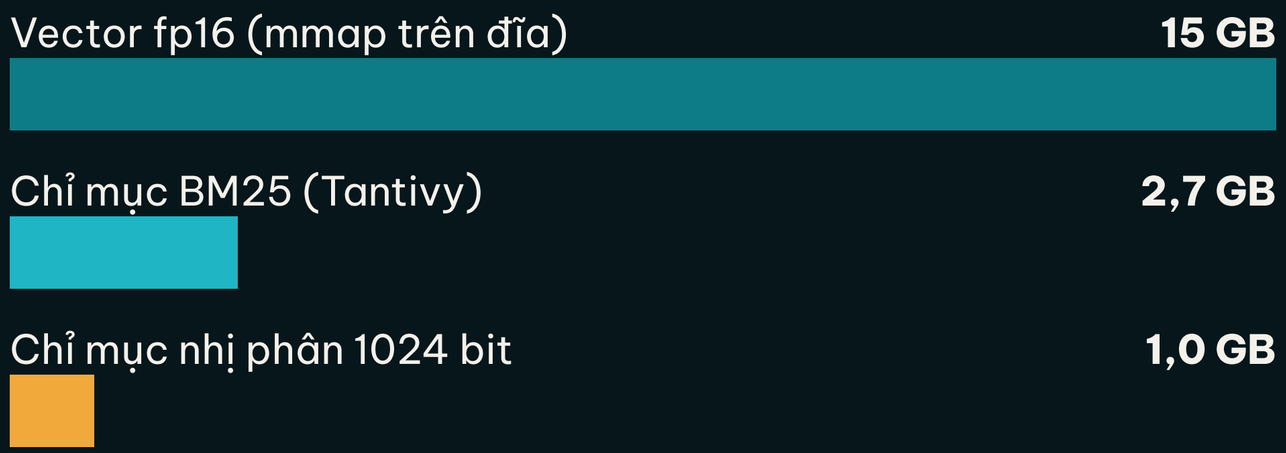
RTX 3050 · 6 GB VRAM

16 GB RAM DÙNG CHUNG

Ổ HDD, 12 NHÂN CPU

Máy này cũng là máy làm việc hằng ngày, nên mọi bước nặng đều có guard: tự tạm dừng khi RAM trống thấp, GPU nóng hoặc VRAM trống thấp.

DUNG LƯỢNG CÁC THÀNH PHẦN



Truy hồi chiếm khoảng 4 GB RAM, VRAM đỉnh của BGE-M3 khoảng 1,3 GB.

7,6 TRIỆU CHUNK TỪ 4,39 TRIỆU URL



→ **7.607.882 chunk**: 76,5% tiếng Trung, 23,5% tiếng Việt.

79,37% → 69,03%: loại 454.068 trang lỗi mã hóa (13,02% số đã crawl), chủ yếu domain tiếng Trung cnkang.

PHẦN BỊ LOẠI	SỐ TRANG
Bị WAF chặn (banned)	875.487
Lỗi mã hóa (cnkang)	454.068
Cần render JavaScript	28.710
Lỗi vĩnh viễn	2.599
Chưa vào chỉ mục	**1.360.864 · 30,97%**

TỪ URL THÔ ĐẾN CÂU TRẢ LỜI XẾP HẠNG

CRAWL

httpx bất đồng bộ, circuit breaker từng domain, checkpoint SQLite

CHUNK

≤ 420 token BGE-M3, overlap 60, văn bản nguyên văn

BM25

Tantivy, bigram chữ Hán

DENSE

BGE-M3, nhị phân 1024 bit

RRF

k = 60, giữ 600 chunk

RERANK

BGE-reranker-v2-m3 có tiêu đề + mục, ghép Qwen3-Reranker-0.6B

Chọn doc: điểm rerank ≥ ngưỡng, tối đa 400 doc mỗi câu

Chọn đoạn: cửa sổ ≤ 900 token ghép từ chunk liền kề

3 → 71

doc tham chiếu mỗi câu: giả định ban đầu 3, đo được 71,0 (trung vị 60, P10 = 12, P90 = 145, tối đa 190)

Bài nộp đầu tiên chỉ trả 3 doc nên chỉ đạt 0,0253. Lời giải: trả hàng trăm doc rồi cắt theo chất lượng.

06 · BÀI HỌC VỀ CÁCH ĐO

BỘ DEV TỰ DỰNG ĐÁNH LỪA

BỘ DEV VIHEALTHQA · 743 CẶP

~1,4 doc / câu

Reranker bị coi là kém RRF: ChunkHit@1 0,225 so với 0,272.

LEADERBOARD THẬT · 600 CÂU

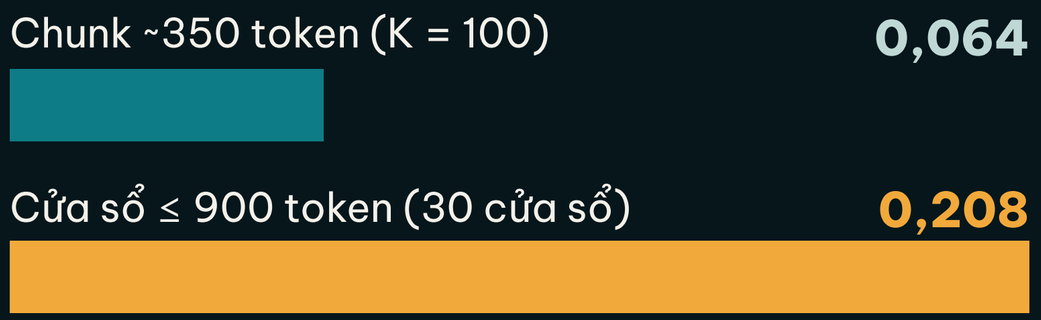
~71 doc / câu

Reranker làm Chunks F2 tăng từ 0,1495 lên 0,1748 (+17% recall, +18% precision).

Nhãn thưa và lệch thì cho kết luận ngược chiều. Chọn K và reranker bằng leaderboard, không bằng dev tự dựng.

07 · CHUNK DÀI THẮNG CHUNK NGẮN

CỬA SỔ ≤ 900 TOKEN TĂNG PRECISION 3,3 LẦN

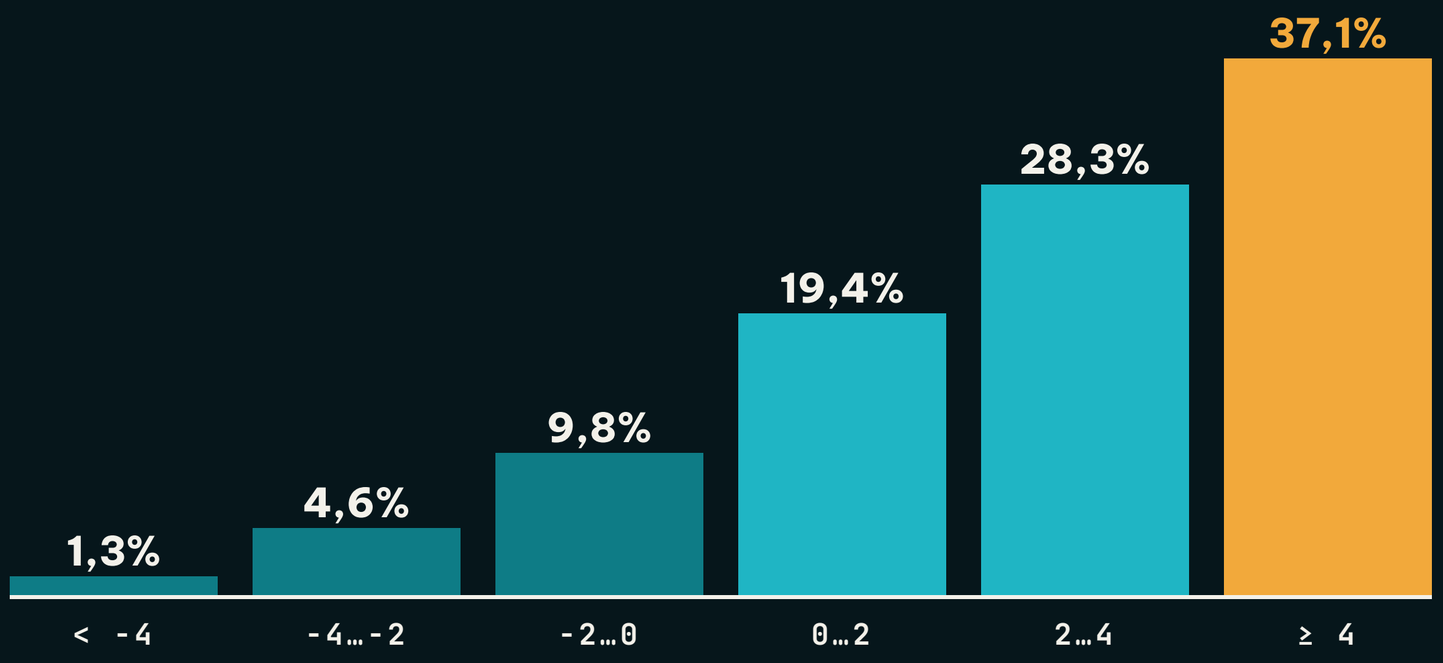


CHUNKS PRECISION, CÙNG CÁCH XẾP HẠNG

Overlap = LCS / độ dài chunk **tham chiếu**. Đoạn nộp càng dài thì càng chứa trọn chunk tham chiếu mà không đổi mẫu số.

Overlap của cửa sổ trúng: trung bình 0,77; 40,7% đạt ≥ 0,9. Cửa sổ 980 token không giúp thêm (precision +5%, số cửa sổ −8%).

CHỌN DOC THEO NGƯỠNG ĐIỂM, KHÔNG THEO K

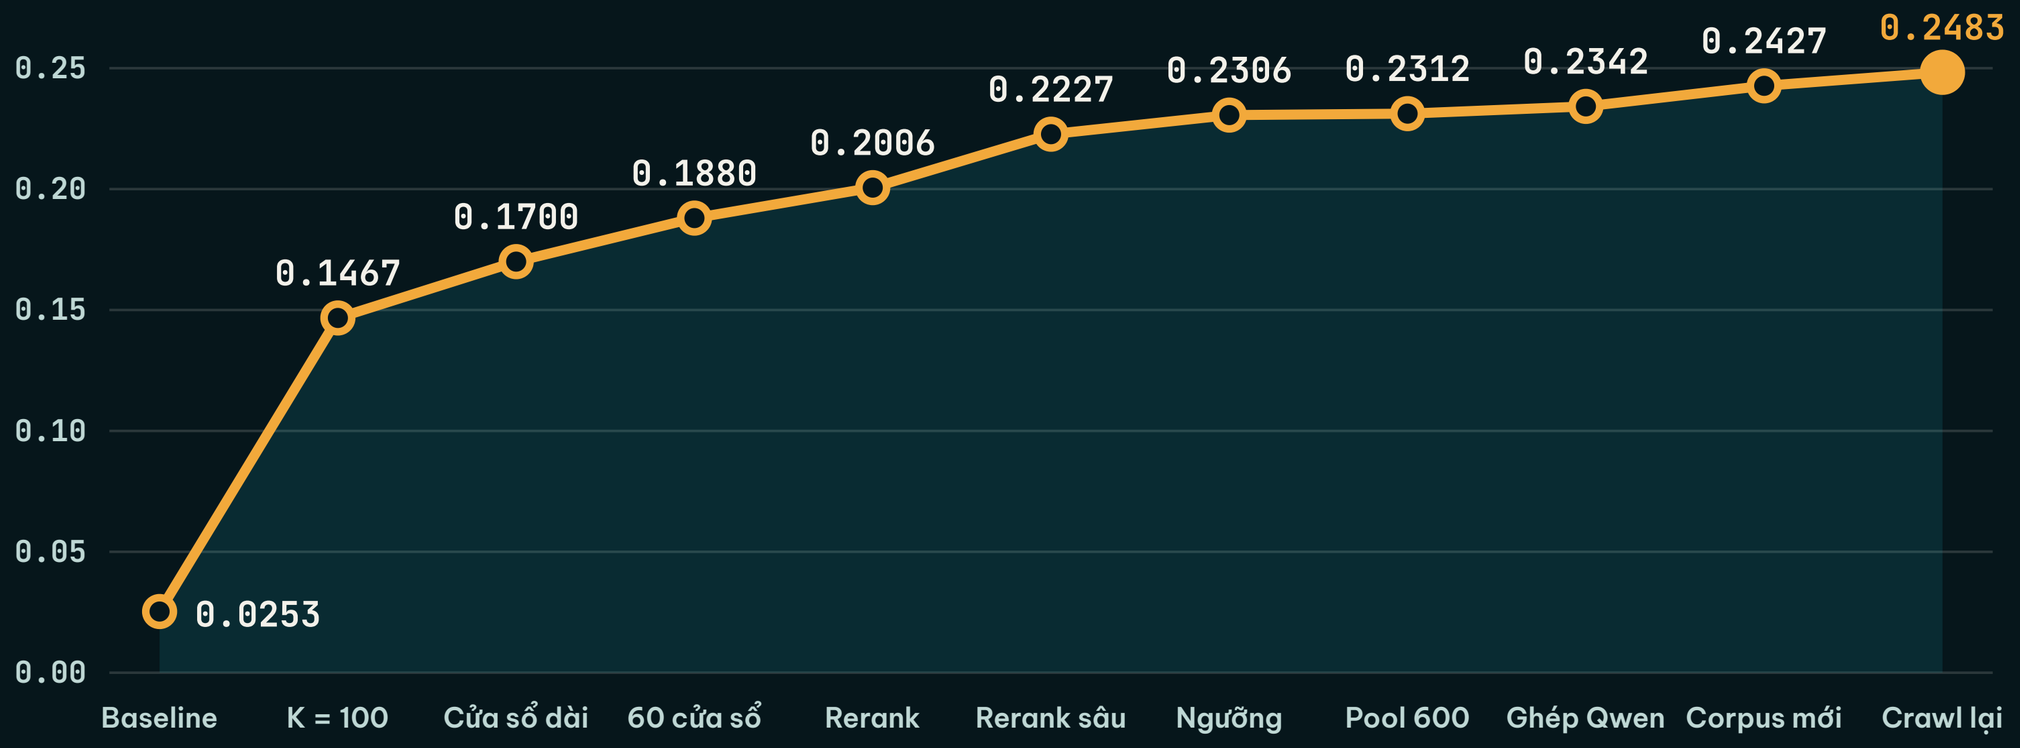


Tỷ lệ cửa sổ trúng theo điểm rerank. Trong cùng nhóm hạng, điểm cao trúng gấp 2 đến 3 lần điểm thấp.

Docs F2: 0,2513 → 0,2698

09 · HÀNH TRÌNH ĐIỂM PUBLIC

TỪ 0,0253 LÊN 0,2483



10 · BẢN PUBLIC CHỐT (BÀI 6106)

FINAL 0,2483

CẤP	F2	PRECISION	RECALL
Docs	**0,2906**	**0,1791**	**0,4016**
Chunks	**0,2060**	**0,2028**	**0,2384**

166,1 doc và khoảng 92 cửa sổ mỗi câu; zip 99,7 MB. So với bài 6039 (0,2427): crawl lại 117 nghìn trang tiếng Việt nâng +0,0056, chủ yếu ở recall tài liệu.

ĐIỂM MẠNH VÀ ĐIỂM NGHẼN

Recall doc 0,40 cao hơn hẳn Precision 0,18: tìm được nhiều doc đúng nhưng còn lẫn nhiều doc sai.

Điểm nghẽn là Precision, tức khả năng phân biệt doc đúng và doc sai.

0,2906
DOCS F2

0,2060
CHUNKS F2

9,8×
SO VỚI BÀI NỘP ĐẦU TIÊN

CHUNK TRƯỢT VÌ SAI DOC

77,2%

Cửa sổ nộp thuộc doc không có chunk nhãn nào (40.664 trên 52.665).

82,4%

Cửa sổ trúng khi doc đã đúng (9.894 trên 12.001 cửa sổ ở doc có nhãn).

4,0%

Chỉ 2.107 cửa sổ ở doc đúng mà trượt đoạn.

Chọn đoạn trong doc đúng đã tốt. Muốn tăng điểm chunk phải chọn doc chính xác hơn.

Chunk nhãn tìm được: 10.151 trên 44.819 (22,6%). Cửa sổ trung bình 665 token.

12 · ĐÃ ĐO VÀ BÁC BỎ

NHỮNG HƯỚNG KHÔNG ĐÁNG LÀM

HƯỚNG	KẾT QUẢ ĐO
BM25 thuần thay RRF	chỉ bằng 54% điểm của RRF ở K = 100
Cửa sổ 980 token	Chunks F2 0,1927 → 0,1897 (precision +5%, số cửa sổ −8%)
Gộp điểm cấp doc	AUC 0,652 → 0,663: không đáng
Cắt số doc theo từng câu	oracle +0,021, quy tắc thực tế +0,006 (kiểm tra chéo)
Tải lại phần tiếng Trung lỗi mã hóa	không làm: 94,2% số cửa sổ trúng là tài liệu tiếng Việt (bằng chứng gián tiếp)

NÓI RÕ ĐIỀU CHƯA BIẾT

600 câu

Điểm Public chỉ từ 600 câu và các ngưỡng chọn trên chính chúng; sai khác ±0,003 là nhiễu. Điểm Private chưa biết.

78,7%

Corpus mới của Ban Tổ chức đã vào chỉ mục (không tính PubMed); còn thiếu khoảng 130 nghìn trang tiếng Việt bị chặn hoặc cần render. Tỷ lệ doc đáp án nằm trong phần thiếu chưa đo.

Tiếng Trung

Chưa thử truy vấn bằng tiếng Trung (dịch hoặc mở rộng) và chưa có nhãn tiếng Trung để đo riêng. Truy vấn tiếng Việt vẫn lấy được tài liệu tiếng Trung nhờ dense đa ngôn ngữ: chúng chiếm 13,1% bài nộp nhưng chỉ 5,8% số cửa sổ trúng.

Bộ chấm đếm token lệch ± ~30 token so với tokenizer BGE-M3, nên mọi cửa sổ chừa biên dưới 1.024 token.

14 · BƯỚC TIẾP THEO

PRECISION LÀ ĐIỂM NGHẼN

01

Viết lại truy vấn bằng model mở nhỏ cho câu hỏi dài kiểu bệnh nhân kể. Chưa đo.

02

Thử truy vấn tiếng Trung trên khoảng 100 câu. Chưa đo.

03

Độ phủ: chỉ thử các domain tiếng Việt bị chặn (khoảng 180 nghìn trang). Chưa đo lợi ích.

CẢM ƠN

LÊ NGỌC TÚ · R2AI GURU STAGE 3

GITHUB.COM/LE-NGOC-TU/
R2AI-GURU-STAGE3-MEDICAL-RETRIEVAL

MÃ NGUỒN, SỐ LIỆU VÀ NHẬT KÝ THỰC NGHIỆM TRONG REPO